
Инвариантный индекс текста на основе собственной размерности при машинном переводе

Marina Kuchina
MIPT
Moscow, Russia
kuchina.ma@phystech.edu

Ivan Papay
MIPT
Moscow, Russia
papai.id@phystech.edu

Andrey Grabovoy
MIPT
Moscow, Russia
grabovoy.av@phystech.edu

Alexander Kildyakov
ICSA
Moscow, Russia
email@ipu.ru

Abstract

В данной работе решается задача поиска близких документов в мультиязычных коллекциях. Для её решения исследуется инвариантность собственной размерности текста при переводе. Также проверяется возможность использования собственной размерности для построения поискового индекса документа. Исследование основано на вычислении собственной размерности для мультиязычных текстов одной тематики и анализе полученных значений. В работе собственная размерность впервые рассматривается как представление текста, устойчивое к переводу. В результате подтверждена инвариантность собственной размерности при переводе и показана возможность построения на её основе поискового индекса, позволяющего находить тематически схожие документы независимо от языка.

Keywords: Intrinsic dimension, Persistent homology dimension, Cross-lingual retrieval, Translation invariance, Natural language processing, Text embeddings

1 Введение

В наши дни растут объёмы информации в мультиязычных цифровых коллекциях, и задача эффективного поиска информации, не ограниченной языковыми барьерами, становится критически важной [1]. Одной из фундаментальных проблем в этой области является поиск семантически близких [2] документов на разных языках. Многие из существующих подходов опираются на параллельные корпуса текстов на разных языках и сложные модели машинного перевода [3]. Альтернативный подход заключается в поиске характеристик текста, инвариантных относительно перевода и отражающих его смысл. В данной работе рассматривается внутренняя размерность текста – характеристика сложности его внутренней структуры. Задача заключается в проверке инвариантности внутренней размерности текста относительно перевода и построении на её основе индекса текста, который можно было бы использовать для поиска похожих по смыслу документов в мультиязычных коллекциях.

В литературе представлено несколько подходов к решению задачи межъязыкового поиска документов. Более ранние подходы основываются на построении общих эмбединговых пространств при помощи кросс-язычных словарей или параллельных

корпусов текстов [4]. Другие методы опираются на количественные меры семантической близости текстов [5]. Современный подход заключается в использовании многоязычных моделей-энкодеров, например, XLM-RoBERTa [6] или RoBERTa [7], проецирующих мультязычные тексты в единое векторное пространство и позволяющие сравнивать полученные представления.

Однако существующие методы обладают рядом ограничений. Так, например, подход [4], основанный на построении общих эмбединговых пространств, строит модель для двух языков и, как следствие, плохо масштабируется на случай мультязычных коллекций. В случае использования энкодерных моделей ряд современных работ, посвящённых исследованию геометрии их представлений, показывает, что эмбединги текстов содержат чувствительные к языку компоненты [8], а также зависят от контекста [9]. Это доказывает, что сравнение эмбедингов в них напрямую может дать нестабильные результаты, так как смысловая информация искажается специфичной для языка и контекстуальной информацией.

В данной работе исследуется внутренняя размерность текста на инвариантность относительно перевода. Для оценки внутренней размерности текста используется метод, основанный на теории персистентной гомологии [10], а именно оценка персистентной размерности (PHD) [11], [12]. Множество эмбедингов фрагмента текста рассматривается как облако точек. Предполагается, что точки лежат на некотором многообразии, размерность которого количественно определяет сложность текста. Метод PHD оценивает размерность многообразия через анализ минимального остовного дерева (MST), построенного на этих точках. Сумма длин рёбер MST, возведённых в степень α , растёт с числом точек по закону $n^{(d-\alpha)/d}$, где d — искомая размерность [13]. Анализ роста суммы с ростом числа точек и подбор параметра α позволяет восстановить искомую размерность d . В современных работах [14] уже показано, что PHD инвариантна относительно перефразирования. В нашей работе проверяется инвариантность PHD относительно перевода. На основе этой гипотезы строится индекс документа как последовательность значений PHD для его фрагментов. Полученная последовательность считается идентификатором текста для поиска в многоязычной коллекции документов.

Для проверки гипотезы об инвариантности PHD относительно перевода использован датасет Wiki-40B [15]. Для статей на одну тему, рассматриваемых в качестве приближения перевода, были получены эмбединги и вычислено значение PHD. Анализ полученных значений подтвердил высокую корреляцию между размерностями для статей на разных языках, что свидетельствует об инвариантности внутренней размерности PHD при переводе. При разбиении текста на фрагменты и вычислении последовательностей PHD для полученных фрагментов был построен поисковый индекс, который позволил находить тематически схожие документы независимо от языка. Результаты свидетельствуют о перспективности использования индексов текстов, основанных на PHD, для поиска текстов в мультязычных коллекциях.

2 Related Work

Topic #1. TODO

Topic #2. TODO

3 Постановка задачи

3.1 Мультязычная коллекция документов

Рассмотрим коллекцию текстов $\mathcal{D}$, написанных на языках из семейства $\mathcal{L}$ на темы из семейства $\mathcal{T}$. Пусть $d_{t,l}$ — текст на языке $l \in \mathcal{L}$ на тему $t \in \mathcal{T}$. Будем считать, что для каждой темы $t \in \mathcal{T}$ и для любой пары языков $l_1, l_2 \in \mathcal{L}$ тексты d_{t,l_1} и d_{t,l_2} являются переводами друг друга. Тогда вся коллекция текстов:

$$\mathcal{D} = \{d_{t,l} \mid l \in \mathcal{L}, t \in \mathcal{T}\}.$$

Обозначим коллекцию текстов на языке l

$$\mathcal{D}_l = \{d_{t,l} \mid t \in \mathcal{T}\},$$

а коллекцию текстов на тему t на разных языках

$$\mathcal{D}_t = \{d_{t,l} \mid l \in \mathcal{L}\}.$$

3.2 Построение индекса текста

После токенизации каждый текст $d_{t,l}$ представим в виде последовательности токенов:

$$d_{t,l} = [w_{t,l}^1, w_{t,l}^2, \dots, w_{t,l}^{N_{t,l}}],$$

где $N_{t,l}$ — длина текста $d_{t,l}$ в токенах.

Пусть также текст $d_{t,l}$ разбит на фрагменты:

$$d_{t,l} = [f_{t,l}^1 \sqcup f_{t,l}^2 \sqcup \dots \sqcup f_{t,l}^{M_{t,l}}],$$

где каждый фрагмент текста является последовательностью токенов этого текста

$$f_{t,l}^k = [w_{t,l}^{k,1}, w_{t,l}^{k,2}, \dots, w_{t,l}^{k,|f_{t,l}^k|}],$$

где $|f_{t,l}^k|$ — длина фрагмента в токенах.

Для каждого текста $d_{t,l}$ и для каждого его фрагмента $f_{t,l}^k$ с помощью языковой модели $\mathcal{M}$ получим эмбединги токенов. Для фрагмента $f_{t,l}^k = [w_{t,l}^{i_k}, \dots, w_{t,l}^{j_k}]$ получим последовательность векторов:

$$\mathcal{M}(f_{t,l}^k) = \mathbf{E}_{t,l}^k \in \mathbb{R}^{|f_{t,l}^k| \times m},$$

где $\mathbf{E}_{t,l}^k = [\mathbf{e}_{t,l}^{k,1}, \mathbf{e}_{t,l}^{k,2}, \dots, \mathbf{e}_{t,l}^{k,|f_{t,l}^k|}]$ — последовательность эмбедингов для $f_{t,l}^k$, m — размерность эмбединга, $\mathbf{e}_{t,l}^{k,s} \in \mathbb{R}^m$.

Для каждого фрагмента $f_{t,l}^k$ для полученного множества эмбедингов $\mathbf{E}_{t,l}^k$ вычислим внутреннюю размерность PHD:

$$\rho(f_{t,l}^k) = \text{PHD}(\mathbf{E}_{t,l}^k).$$

Для текста $d_{t,l}$ его индексом назовём последовательность внутренних размерностей его фрагментов.

$$I(d_{t,l}) = \left(\rho(f_{t,l}^1), \rho(f_{t,l}^2), \dots, \rho(f_{t,l}^{M_{t,l}}) \right) \in \mathbb{R}^{M_{t,l}}.$$

Таким образом, каждому тексту $d_{t,l}$ сопоставляется его индекс $I(d_{t,l})$, полученный в результате цепочки преобразований:

$$\begin{aligned} d_{t,l} &\rightarrow [w_{t,l}^1, w_{t,l}^2, \dots, w_{t,l}^{N_{t,l}}] \rightarrow [f_{t,l}^1 \sqcup f_{t,l}^2 \sqcup \dots \sqcup f_{t,l}^{M_{t,l}}] \xrightarrow{\mathcal{M}} \\ &\xrightarrow{\mathcal{M}} [\mathbf{E}_{t,l}^1, \mathbf{E}_{t,l}^2, \dots, \mathbf{E}_{t,l}^{M_{t,l}}] \xrightarrow{\text{PHD}} [\rho(f_{t,l}^1), \rho(f_{t,l}^2), \dots, \rho(f_{t,l}^{M_{t,l}})] \rightarrow I(d_{t,l}). \end{aligned}$$

Индекс $I(d_{t,l})$ рассматривается как инвариантное относительно перевода представление текста.

3.3 Оценка внутренней размерности

Для оценки внутренней размерности текста используется метод, основанный на теории персистентной гомологии [10], а именно оценка персистентной размерности (PHD) [11], [12].

Множество точек $E_{t,l}^k = \{\mathbf{e}_{t,l}^{k,1}, \dots, \mathbf{e}_{t,l}^{k,|f_{t,l}^k|}\} \subset \mathbb{R}^m$, соответствующее эмбедингам токенов фрагмента, рассматривается как облако точек в пространстве $\mathbb{R}^m$. Предполагается, что эти точки лежат вблизи некоторого гладкого многообразия малой размерности d ,

вложенного в $\mathbb{R}^m$ [16]. Значение d может быть интерпретировано как число степеней свободы, определяющее сложность текста: чем больше разнообразных тем и смысловых элементов содержится в фрагменте, тем выше размерность многообразия.

Оценка PHD основана на понятии персистентной гомологии. Используется следующий подход к изучению формы облака точек. Рассматривается порог r , который последовательно увеличивается. При увеличении r появляются и исчезают топологические признаки разной размерности: связные компоненты (0-мерные признаки), нетривиальные циклы (1-мерные признаки), туннели (2-мерные признаки) и т.д. Набор i -мерных признаков — персистентная гомология PH_i . Для каждого такого признака $\gamma \in PH_i$ фиксируется момент его рождения t_{birth} (наименьший порог, при котором признак появляется) и момент смерти t_{death} (порог, при котором он исчезает). Разность $I(\gamma) = t_{\text{death}} - t_{\text{birth}}$ называется временем жизни признака. Оценка PHD основана на анализе полученных времён жизни для разных признаков.

Важный частный случай возникает при рассмотрении только 0-мерных признаков (компонент связности). В этом случае оценка PHD может быть выражена через минимальное остовное дерево (MST) — связный граф без циклов, соединяющий все точки с минимальной суммой длин рёбер [14]. В этом случае длины рёбер MST будут соответствовать временам жизни компонент связности.

Рассмотрим конечное множество точек $X = \{x_1, x_2, \dots, x_N\} \subset \mathbb{R}^m$. Построим на нём MST.

Определим взвешенную сумму длин рёбер MST:

$$E_\alpha(X) = \sum_{e \in \text{MST}(X)} |e|^\alpha,$$

где $|e|$ — длина ребра e , а $\alpha > 0$ — параметр.

Классический результат теории вероятностей [17] утверждает, что если точки x_i являются независимыми одинаково распределёнными случайными величинами с носителем, компактно вложенным в $\mathbb{R}^d$, то с вероятностью 1

$$E_\alpha(X_n) \sim C \cdot n^{(d-\alpha)/d} \quad \text{при } n \rightarrow \infty,$$

где X_n — выборка из n точек, эквивалентность $\sim$ означает, $\frac{E_\alpha(X_n)}{C \cdot n^{(d-\alpha)/d}} \rightarrow 1$.

Отсюда следует, что $E_\alpha(X_n)$ остаётся ограниченным при $n \rightarrow \infty$ тогда и только тогда, когда $\alpha \geq d$. Отсюда определяется:

$$\dim_{\text{MST}}(M) = \inf\{d \mid \exists C : \forall \text{ конечных } X \subset M : E_d(X) \leq C\}.$$

Размерность $\dim_{\text{MST}}(M)$ совпадает с размерностью PHD.

Оценить d можно из соотношения

$$\log E_\alpha(X_n) \approx \left(1 - \frac{\alpha}{d}\right) \log n + \text{const},$$

получив оценку для $1 - \frac{\alpha}{d}$ с помощью линейной регрессии.

3.4 Проверка инвариантности PHD относительно перевода

Необходимо проверить, что внутренняя размерность PHD сохраняется при переводе. Для этого для каждой темы t и всех пар языков $l_1, l_2 \in \mathcal{L}$ вычисляется разность

$$\Delta_{t,l_1,l_2} = |\rho(d_{t,l_1}) - \rho(d_{t,l_2})|.$$

Если PHD инвариантна относительно перевода, распределение Δ для фиксированного t должно быть сосредоточено около нуля. Количественно оценить это можно с помощью:

1. Подсчёта MAE по всем парам одной темы и сравнения с MAE для аналогичных пар для разных тем — $\Delta_{t_1,t_2,l_1,l_2} = |\rho(d_{t_1,l_1}) - \rho(d_{t_2,l_2})|$. Для пар одной темы MAE должно быть значительно меньше;
2. Вычисления коэффициента корреляции Пирсона между $\rho(d_{t,l_1})$ и $\rho(d_{t,l_2})$ при фиксированном t для различных l_1 и l_2 . Коэффициент корреляции должен быть близок к 1.

3.5 Использование индекса для поиска схожих документов

На основе индексов $I(d_{t,l})$ требуется построить функцию ранжирования, позволяющую по документу-запросу $d_{t,l}$ на произвольном языке $l \in \mathcal{L}$ упорядочить все документы коллекции $\mathcal{D}$ так, чтобы близкие документы, то есть документы той же темы, оказались выше других.

Для индекса документа-запроса d_{t_q,l_q} , равного $I_q = I(d_{t_q,l_q})$, вычисляются расстояния до индексов всех документов $d_{t,l} \in \mathcal{D}$:

$$r(d_{t,l}) = \text{dist}(I_q, I(d_{t,l})).$$

Документы ранжируются по возрастанию $r(d_{t,l})$, формируя ранжированный список.

Обозначим через $R_q = \{d_{t_q,l} \mid l \in \mathcal{L}, l \neq l_q\}$ множество документов, релевантных документу-запросу d_{t_q,l_q} — документы той же темы на других языках. Для полученного ранжированного списка определим:

- Точность среди первых k результатов:

$$\text{Precision@}k(q) = \frac{\#\{d \in R_q \mid d \text{ в первых } k \text{ позициях}\}}{k};$$

- Полноту среди первых k результатов:

$$\text{Recall@}k(q) = \frac{\#\{d \in R_q \mid d \text{ в первых } k \text{ позициях}\}}{|R_q|};$$

- Среднюю точность:

$$\text{AP}(q) = \frac{1}{|R_q|} \sum_{i: d_i \in R_q} \text{Precision@}i(q),$$

где d_i — документ на позиции i в ранжированном списке.

Итоговые метрики получаются усреднением по всем запросам из множества запросов Q :

$$\text{mAP} = \frac{1}{|Q|} \sum_{q \in Q} \text{AP}(q),$$

$$\text{Precision@}k = \frac{1}{|Q|} \sum_{q \in Q} \text{Precision@}k(q),$$

$$\text{Recall@}k = \frac{1}{|Q|} \sum_{q \in Q} \text{Recall@}k(q).$$

Цель работы — показать, что использование индекса на основе РНД позволяет достичь более высокого качества мультязычного поиска по сравнению с другими подходами.

4 Preliminaries

4.1 General notation

In this section, we introduce the general notation used in the rest of the paper and the basic assumptions.

4.2 Assumptions

TODO

5 Method

6 Experiments

6.1 Baseline experiment

Для первичной проверки гипотезы об инвариантности внутренней размерности относительно перевода проведён вычислительный эксперимент на датасете Wiki-40B [15].

Сравнение значений внутренней размерности PHD проведено для текстов на русском и английском языках. Из датасета были выбраны 500 статей, имеющие одинаковый идентификатор `wikidata_id`, то есть являющиеся статьями на одну тему на разных языках. Согласно нашему предположению, такие статьи можно рассматривать как приближённый перевод друг друга.

Для каждой из выбранных статей убрана служебная разметка (маркеры начала секций, параграфов). Затем получены эмбединги с помощью модели Qwen2.5-0.5B, на основе которых для каждой статьи вычислены значения PHD согласно алгоритму, предложенному в [14].

На рис. 1 представлено сравнение значений PHD для русских и английских версий одних и тех же статей. Рис. 2 показывает разность этих значений (значение для русского языка минус значение для английского).




Рис. 1: Сравнение PHD для русских и английских статей

Полученные результаты демонстрируют систематическое смещение: значения PHD для русскоязычных текстов в среднем на 1.5–2 превышают соответствующие значения для англоязычных текстов. Это может быть обусловлено тем, что тексты не являются точным переводом друг друга. Также такие результаты могут быть специфичны для используемой модели, что требует повторения эксперимента с использованием других языковых моделей. В случае получения аналогичных результатов, демонстрирующих смещение, при использовании других моделей можно будет сделать предположение о том, что внутренняя размерность PHD не является инвариантной к переводу и определённым образом зависит от языка текста.

7 Discussion

TODO




Рис. 2: Разность PHD для текстов на английском и русском

8 Conclusion

TODO

Список литературы

- [1] Oleg Bakhteev, Alexandr Ogaltsov, Andrey Khazov, Kamil Safin, and Rita Kuznetsova. Crosslang: the system of cross-lingual plagiarism detection. In Workshop on Document Intelligence at NeurIPS 2019, 2019. URL <https://openreview.net/forum?id=BkxiG6qqIr>.
- [2] Alexander Panchenko, Natalia Loukachevitch, Dmitry Ustalov, Denis Paperno, Christian Meyer, and Natalia Konstantinova. Russe: The first workshop on russian semantic similarity, 2018. URL <https://arxiv.org/abs/1803.05820>.
- [3] K. Avetisyan, G. Gritsay, and A. Grabovoy. Cross-lingual plagiarism detection: Two are better than one. Programming and Computer Software, 49(4):346–354, July 2023. ISSN 1608-3261. doi: 10.1134/s0361768823040138. URL <http://dx.doi.org/10.1134/s0361768823040138>.
- [4] Ivan Vulić and Marie-Francine Moens. Monolingual and cross-lingual information retrieval models based on (bilingual) word embeddings. In Proceedings of the 38th International ACM SIGIR Conference on Research and Development in Information Retrieval, New York, NY, USA, August 2015. ACM. URL https://www.researchgate.net/publication/299487231_Monolingual_and_Cross-Lingual_Information_Retrieval_Models_Based_on_Bilingual_Word_Embeddings.
- [5] Katharina Wäschle. Quantifying cross-lingual semantic similarity for natural language processing applications. 01 2015. URL <https://arxiv.org/abs/1911.02116>.
- [6] Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer, and Veselin Stoyanov. Unsupervised cross-lingual representation learning at scale, 2020. URL <https://arxiv.org/abs/1911.02116>.
- [7] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. Roberta: A robustly optimized bert pretraining approach, 2019. URL <https://arxiv.org/abs/1907.11692>.

- [8] Tyler A. Chang, Zhuowen Tu, and Benjamin K. Bergen. The geometry of multilingual language model representations, 2022. URL <https://arxiv.org/abs/2205.10964>.
- [9] Kawin Ethayarajh. How contextual are contextualized word representations? comparing the geometry of bert, elmo, and gpt-2 embeddings, 2019. URL <https://arxiv.org/abs/1909.00512>.
- [10] S. A. Barannikov. The framed morse complex and its invariants, December 1994. URL https://www.researchgate.net/publication/267672645_The_Framed_Morse_complex_and_its_invariants.
- [11] Henry Adams, Manuchehr Aminian, Elin Farnell, Michael Kirby, Joshua Mirth, Rachel Neville, Chris Peterson, and Clayton Shonkwiler. A Fractal Dimension for Measures via Persistent Homology, page 1–31. Springer International Publishing, 2020. ISBN 9783030434083. doi: 10.1007/978-3-030-43408-3_1. URL http://dx.doi.org/10.1007/978-3-030-43408-3_1.
- [12] Benjamin Schweinhart. Persistent homology and the upper box dimension, 2019. URL <https://arxiv.org/abs/1802.00533>.
- [13] Tolga Birdal, Aaron Lou, Leonidas Guibas, and Umut Şimşekli. Intrinsic dimension, persistent homology and generalization in neural networks, 2021. URL <https://arxiv.org/abs/2111.13171>.
- [14] Eduard Tulchinskii, Kristian Kuznetsov, Laida Kushnareva, Daniil Cherniavskii, Serguei Barannikov, Irina Piontkovskaya, Sergey Nikolenko, and Evgeny Burnaev. Intrinsic dimension estimation for robust detection of ai-generated texts, 2023. URL <https://arxiv.org/abs/2306.04723>.
- [15] Mandy Guo, Zihang Dai, Denny Vrandečić, and Rami Al-Rfou. Wiki-40B: Multilingual language model dataset. In Nicoletta Calzolari, Frédéric Béchet, Philippe Blache, Khalid Choukri, Christopher Cieri, Thierry Declerck, Sara Goggi, Hitoshi Isahara, Bente Maegaard, Joseph Mariani, Hélène Mazo, Asuncion Moreno, Jan Odijk, and Stelios Piperidis, editors, Proceedings of the Twelfth Language Resources and Evaluation Conference, pages 2440–2452, Marseille, France, May 2020. European Language Resources Association. ISBN 979-10-95546-34-4. URL <https://aclanthology.org/2020.lrec-1.297/>.
- [16] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. Deep Learning. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [17] J. Michael Steele. Growth rates of euclidean minimal spanning trees with power weighted edges. The Annals of Probability, 16(4), October 1988. ISSN 0091-1798. doi: 10.1214/aop/1176991596. URL <http://dx.doi.org/10.1214/aop/1176991596>.

A Appendix / supplemental material

A.1 Additional experiments / Proofs of Theorems

TODO