Инвариантный индекс текста на основе собственной размерности при машинном переводе

Marina Kuchina
MIPT
Moscow, Russia
kuchina.ma@phystech.edu

Ivan Papay
MIPT
Moscow, Russia
papai.id@phystech.edu

Andrii Hraboviy
MIPT
Moscow, Russia
email@phystech.edu

Alexander Kildyakov
MIPT
Moscow, Russia
email@phystech.edu

Abstract

В данной работе решается задача поиска близких документов в мультиязычных коллекциях. Для её решения исследуется инвариантность собственной размерности текста при переводе. Также проверяется возможность использования собственной размерности для построения поискового индекса документа. Исследование основано на вычислении собственной размерности для мультиязычных текстов одной тематики и анализе полученных значений. В работе собственная размерность впервые рассматривается как представление текста, устойчивое к переводу. В результате подтверждена инвариантность собственной размерности при переводе и показана возможность построения на её основе поискового индекса, позволяющего находить тематически схожие документы независимо от языка.

Keywords: Intrinsic dimension, Persistent homology dimension, Cross-lingual retrieval, Translation invariance, Natural language processing, Text embeddings

1 Введение

В наши дни растут объёмы информации в мультиязычных цифровых коллекциях, и задача эффективного поиска информации, не ограниченной языковыми барьерами, становится критически важной [1]. Одной из фундаментальных проблем в этой области является поиск семантически близких [2] документов на разных языках. Многие из существующих подходов опираются на параллельные корпуса текстов на разных языках и сложные модели машинного перевода [3]. Альтернативный подход заключается в поиске характеристик текста, инвариантных относительно перевода и отражающих его смысл. В данной работе рассматривается внутренняя размерность текста – характеристика сложности его внутренней структуры. Задача заключается в проверке инвариантности внутренней размерности текста относительно перевода и построении на её основе индекса текста, который можно было бы использовать для поиска похожих по смыслу документов в мультиязычных коллекциях.

В литературе представлено несколько подходов к решению задачи межъязыкового поиска документов. Более ранние подходы основываются на построении общих эмбеддинговых пространств при помощи кросс-язычных словарей или параллельных

39th Conference on Neural Information Processing Systems (NeurIPS 2025).

корпусов текстов [4]. Другие методы опираются на количественные меры семантической близости текстов [5]. Современный подход заключается в использовании многоязычных моделей-энкодеров, например, XLM-RoBERTa [6] или RoBERTa [7], проецирующих мультиязычные тексты в единое векторное пространство и позволяющие сравнивать полученные представления.

Однако существующие методы обладают рядом ограничений. Так, например, подход [4], основанный на построении общих эмбеддинговых пространств, строит модель для двух языков и, как следствие, плохо масштабируется на случай мультиязычных коллекций. В случае использования энкодерных моделей ряд современных работ, посвящённых исследованию геометрии их представлений, показывает, что эмбеддинги текстов содержат чувствительные к языку компоненты [8], а также зависят от контекста [9]. Это доказывает, что сравнение эмбедингов в них напрямую может дать нестабильные результаты, так как смысловая информация искажается специфичной для языка и контекстуальной информацией.

В данной работе исследуется внутренняя размерность текста на инвариантность относительно перевода. Для оценки внутренней размерности текста используется метод, основанный на теории персистентной гомологии [10], а именно оценка персистентной размерности (PHD) [11], [12]. Множество эмбеддингов фрагмента текста рассматривается как облако точек. Предполагается, что точки лежат на некотором многообразии, размерность которого количественно определяет сложность текста. Метод PHD оценивает размерность многообразия через анализ минимального остовного дерева (MST), построенного на этих точках. Сумма длин рёбер MST, возведённых в степень α, растёт с числом точек по закону $n^{(d-\alpha)/d}$, где d — искомая размерность [13]. Анализ роста суммы с ростом числа точек и подбор параметра α позволяет восстановить искомую размерность d. В современных работах [14] уже показано, что PHD инвариантна относительно перефразирования. В нашей работе проверяется инвариантность PHD относительно перевода. На основе этой гипотезы строится индекс документа как последовательность значений PHD для его фрагментов. Полученная последовательность считается идентификатором текста для поиска в многоязычной коллекции документов.

Для проверки гипотезы об инвариантности PHD относительно перевода использован датасет Wiki-40B [15]. Для статей на одну тему, рассматриваемых в качестве приближения перевода, были получены эмбеддинги и вычислено значение PHD. Анализ полученных значений подтвердил высокую корреляцию между размерностями для статей на разных языках, что свидетельствует об инвариантности внутренней размерности PHD при переводе. При разбиении текста на фрагменты и вычислении последовательностей PHD для полученных фрагментов был построен поисковый индекс, который позволил находить тематически схожие документы независимо от языка. Результаты свидетельствуют о перспективности использования индексов текстов, основанных на PHD, для поиска текстов в мультиязычных коллекциях.

2 Related Work

Topic #1. TODO

Topic #2. TODO

3 Постановка задачи

3.1 Мультиязычная коллекция документов

Рассмотрим коллекцию текстов $\mathcal{D}$, написанных на языках из семейства $\mathcal{L}$ на темы из семейства $\mathcal{T}$. Пусть $d_{t,l}$ — текст на языке $l \in \mathcal{L}$ на тему $t \in \mathcal{T}$. Будем считать, что для каждой темы $t \in \mathcal{T}$ и для любой пары языков $l_1, l_2 \in \mathcal{L}$ тексты d_{t,l_1} и d_{t,l_2} являются переводами друг друга. Тогда вся коллекция текстов:

$$\mathcal{D} = \{d_{t,l} \mid l \in \mathcal{L}, t \in \mathcal{T}\}.$$

Обозначим коллекцию текстов на языке l

$$\mathcal{D}_l = \{d_{t,l} \mid t \in \mathcal{T}\},$$

а коллекцию текстов на тему t на разных языках

$$\mathcal{D}_t = \{d_{t,l} \mid l \in \mathcal{L}\}.$$

3.2 Построение индекса текста

После токенизации каждый текст $d_{t,l}$ представим в виде последовательности токенов:

$$d_{t,l} = [w_{t,l}^1, w_{t,l}^2, \ldots, w_{t,l}^{N_{t,l}}],$$

где $N_{t,l}$ — длина текста $d_{t,l}$ в токенах.

Пусть также текст $d_{t,l}$ разбит на фрагменты:

$$d_{t,l} = [f_{t,l}^1 \sqcup f_{t,l}^2 \sqcup \cdots \sqcup f_{t,l}^{M_{t,l}}],$$

где каждый фрагмент текста является последовательностью токенов этого текста

$$f_{t,l}^k = [w_{t,l}^{k,1}, w_{t,l}^{k,2}, \ldots, w_{t,l}^{k,|f_{t,l}^k|}],$$

где $|f_{t,l}^k|$ — длина фрагмента в токенах.

Для каждого текста $d_{t,l}$ и для каждого его фрагмента $f_{t,l}^k$ с помощью языковой модели $\mathcal{M}$ получим эмбеддинги токенов. Для фрагмента $f_{t,l}^k = [w_{t,l}^{i_k}, \ldots, w_{t,l}^{j_k}]$ получим последовательность векторов:

$$\mathcal{M}(f_{t,l}^k) = \mathbf{E}_{t,l}^k \in \mathbb{R}^{|f_{t,l}^k| \times m},$$

где $\mathbf{E}_{t,l}^k = [\mathbf{e}_{t,l}^{k,1}, \mathbf{e}_{t,l}^{k,2}, \ldots, \mathbf{e}_{t,l}^{k,|f_{t,l}^k|}]$ — последовательность эмбеддингов для $f_{t,l}^k$, m — размерность эмбеддинга, $\mathbf{e}_{t,l}^{k,s} \in \mathbb{R}^m$.

Для каждого фрагмента $f_{t,l}^k$ для полученного множества эмбеддингов $\mathbf{E}_{t,l}^k$ вычислим внутреннюю размерность PHD:

$$\rho\left(f_{t,l}^k\right) = \mathrm{PHD}\left(\mathbf{E}_{t,l}^k\right).$$

Для текста $d_{t,l}$ его индексом назовём последовательность внутренних размерностей его фрагментов.

$$I\left(d_{t,l}\right) = \left(\rho\left(f_{t,l}^1\right), \rho\left(f_{t,l}^2\right), \ldots, \rho\left(f_{t,l}^{M_{t,l}}\right)\right) \in \mathbb{R}^{M_{t,l}}.$$

Таким образом, каждому тексту $d_{t,l}$ сопоставляется его индекс $I\left(d_{t,l}\right)$, полученный в результате цепочки преобразований:

$$d_{t,l} \to [w_{t,l}^1, w_{t,l}^2, \ldots, w_{t,l}^{N_{t,l}}] \to [f_{t,l}^1 \sqcup f_{t,l}^2 \sqcup \cdots \sqcup f_{t,l}^{M_{t,l}}] \xrightarrow{\mathcal{M}}$$
$$\xrightarrow{\mathcal{M}} [\mathbf{E}_{t,l}^1, \mathbf{E}_{t,l}^2, \ldots, \mathbf{E}_{t,l}^{M_{t,l}}] \xrightarrow{\mathrm{PHD}} [\rho\left(f_{t,l}^1\right), \rho\left(f_{t,l}^2\right), \ldots, \rho\left(f_{t,l}^{M_{t,l}}\right)] \to I(d_{t,l}).$$

Индекс $I(d_{t,l})$ рассматривается как инвариантное относительно перевода представление текста.

4 Preliminaries

4.1 General notation

In this section, we introduce the general notation used in the rest of the paper and the basic assumptions.

4.2 Assumptions

TODO

5 Method

6 Experiments

To verify the theoretical estimates obtained, we conducted a detailed empirical study...

7 Discussion

TODO

8 Conclusion

TODO

Список литературы

[1] Oleg Bakhteev, Alexandr Ogaltsov, Andrey Khazov, Kamil Safin, and Rita Kuznetsova. Crosslang: the system of cross-lingual plagiarism detection. In Workshop on Document Intelligence at NeurIPS 2019, 2019. URL https://openreview.net/forum?id=BkxiG6qqIr.

[2] Alexander Panchenko, Natalia Loukachevitch, Dmitry Ustalov, Denis Paperno, Christian Meyer, and Natalia Konstantinova. Russe: The first workshop on russian semantic similarity, 2018. URL https://arxiv.org/abs/1803.05820.

[3] K. Avetisyan, G. Gritsay, and A. Grabovoy. Cross-lingual plagiarism detection: Two are better than one. Programming and Computer Software, 49(4):346–354, July 2023. ISSN 1608-3261. doi: 10.1134/s0361768823040138. URL http://dx.doi.org/10.1134/s0361768823040138.

[4] Ivan Vulić and Marie-Francine Moens. Monolingual and cross-lingual information retrieval models based on (bilingual) word embeddings. In Proceedings of the 38th International ACM SIGIR Conference on Research and Development in Information Retrieval, New York, NY, USA, August 2015. ACM. URL https://www.researchgate.net/publication/299487231_Monolingual_and_Cross-Lingual_Information_Retrieval_Models_Based_on_Bilingual_Word_Embeddings.

[5] Katharina Wäschle. Quantifying cross-lingual semantic similarity for natural language processing applications. 01 2015. URL https://arxiv.org/abs/1911.02116.

[6] Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer, and Veselin Stoyanov. Unsupervised cross-lingual representation learning at scale, 2020. URL https://arxiv.org/abs/1911.02116.

[7] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. Roberta: A robustly optimized bert pretraining approach, 2019. URL https://arxiv.org/abs/1907.11692.

[8] Tyler A. Chang, Zhuowen Tu, and Benjamin K. Bergen. The geometry of multilingual language model representations, 2022. URL https://arxiv.org/abs/2205.10964.

[9] Kawin Ethayarajh. How contextual are contextualized word representations? comparing the geometry of bert, elmo, and gpt-2 embeddings, 2019. URL https://arxiv.org/abs/1909.00512.

[10] S. A. Barannikov. The framed morse complex and its invariants, December 1994. URL https://www.researchgate.net/publication/267672645_The_Framed_Morse_complex_and_its_invariants.

[11] Henry Adams, Manuchehr Aminian, Elin Farnell, Michael Kirby, Joshua Mirth, Rachel Neville, Chris Peterson, and Clayton Shonkwiler. A Fractal Dimension for Measures via Persistent Homology, page 1–31. Springer International Publishing, 2020. ISBN 9783030434083. doi: 10.1007/978-3-030-43408-3_1. URL http://dx.doi.org/10.1007/978-3-030-43408-3_1.

[12] Benjamin Schweinhart. Persistent homology and the upper box dimension, 2019. URL https://arxiv.org/abs/1802.00533.

[13] Tolga Birdal, Aaron Lou, Leonidas Guibas, and Umut Şimşekli. Intrinsic dimension, persistent homology and generalization in neural networks, 2021. URL https://arxiv.org/abs/2111.13171.

[14] Eduard Tulchinskii, Kristian Kuznetsov, Laida Kushnareva, Daniil Cherniavskii, Serguei Barannikov, Irina Piontkovskaya, Sergey Nikolenko, and Evgeny Burnaev. Intrinsic dimension estimation for robust detection of ai-generated texts, 2023. URL https://arxiv.org/abs/2306.04723.

[15] Mandy Guo, Zihang Dai, Denny Vrandečić, and Rami Al-Rfou. Wiki-40B: Multilingual language model dataset. In Nicoletta Calzolari, Frédéric Béchet, Philippe Blache, Khalid Choukri, Christopher Cieri, Thierry Declerck, Sara Goggi, Hitoshi Isahara, Bente Maegaard, Joseph Mariani, Hélène Mazo, Asuncion Moreno, Jan Odijk, and Stelios Piperidis, editors, Proceedings of the Twelfth Language Resources and Evaluation Conference, pages 2440–2452, Marseille, France, May 2020. European Language Resources Association. ISBN 979-10-95546-34-4. URL https://aclanthology.org/2020.lrec-1.297/.

A Appendix / supplemental material

A.1 Additional experiments / Proofs of Theorems

TODO