

DOI: 10.15514/ISPRAS-2025-37(1)-1



Зависимость внутренней размерности текста от языка

Аннотация. В работе исследуется зависимость внутренней размерности текста от языка. Проверяется гипотеза о том, что внутренняя размерность инвариантна относительно перевода. Исследование проведено на мультязычном корпусе текстов, состоящем из текстов одинакового содержания, переведённых на несколько языков. Для каждого текста на основе эмбедингов токенов, полученных с помощью языковой модели, вычислена внутренняя размерность, после чего проведён сравнительный анализ полученных значений. В результате анализа гипотеза об инвариантности внутренней размерности при переводе отвергается; подтверждается, что внутренняя размерность зависит от языка. Показано, что синтетические языки с богатой морфологией дают более высокие значения, чем аналитические.

Ключевые слова: внутренняя размерность; персистентная размерность; инвариантность перевода; эмбединги текстов; обработка естественного языка.

Dependence of Text Intrinsic Dimension on Language

Abstract. This work investigates the dependence of the intrinsic dimension of a text on its language. The hypothesis that the intrinsic dimension is invariant under translation is tested. The study is conducted on a multilingual corpus consisting of texts with the same content, translated into several languages. For each text, the intrinsic dimension is computed based on token embeddings obtained from a language model, followed by a comparative analysis of the resulting values. The analysis rejects the hypothesis of invariance under translation, confirming that the intrinsic dimension depends on the language. It is shown that synthetic languages with rich morphology give higher values than analytic ones.

Keywords: intrinsic dimension; persistent homology dimension; translation invariance; text embeddings; natural language processing.

1. Введение

Современные языковые модели преобразуют текст в многомерные векторные пространства, геометрические свойства которых активно изучаются [1, 2]. Одной из важных характеристик таких пространств является внутренняя размерность — мера, определяющая минимальное количество параметров, необходимых для описания набора точек в многомерном пространстве. Маленькое значение внутренней размерности говорит об однородности и связности данных, а высокая внутренняя размерность характерна для неоднородных и разрозненных данных [3].

Существуют различные подходы к оценке внутренней размерности: локальные (MLE, TwoNN), фрактальные (MADA) и глобальные (PCA) [4]. Для текстовых данных оказывается эффективным метод, основанный на персистентной гомологии (англ. persistent homology

dimension, PHD) [5, 6]. В отличие от локальных методов эта оценка устойчива к шуму и более эффективна на выборках небольшого размера [7, 8].

Однако эти исследования сфокусированы на свойствах PHD в рамках одного языка. Известно, что мультязычные модели имеют различную производительность для разных языков [9]. Также исследования показывают, что в мультязычных моделях эмбединги содержат как общие компоненты, так и специфичные для конкретного языка [10]. Уже на этапе токенизации тексты могут быть по-разному разбиты на токены в зависимости от морфологических свойств языка [11]. Всё это указывает на то, что языковые модели по-разному работают с различными языками, в связи с чем внутренняя размерность скрытых представлений текста тоже может изменяться.

В данной работе исследуется зависимость внутренней размерности текста от языка. Для оценки размерности используется PHD. Множество эмбедингов токенов текста рассматривается как облако точек, предположительно лежащих вблизи многообразия малой размерности. Размерность этого многообразия называется внутренней размерностью. Значение PHD оценивает сложность текста [7]. Ранее было показано, что PHD инвариантна относительно перефразирования [8]. В нашей работе проверяется, сохраняется ли эта инвариантность при переводе текста на другой язык, и выявляются языковые факторы, влияющие на значение PHD.

Для проверки гипотезы об инвариантности PHD относительно перевода использован датасет Wiki-40B [12]. На выборке из 500 статей, переведённых на 18 языков, с помощью модели Qwen2.5-0.5B [13] получены эмбединги токенов и вычислены значения PHD. Статистический анализ показал, что для разных языков значения внутренней размерности коррелируют друг с другом, но статистически значимо отличаются. То есть внутренняя размерность не инвариантна относительно перевода. Обнаружена связь внутренней размерности с морфологическим типом языка: для синтетических языков (русский, немецкий, польский и др.) среднее значение PHD выше, чем для аналитических (английский, французский, испанский и др.). Анализ токенизации показывает, что в синтетических языках слова разбиваются BPE на большее число токенов, что расширяет пространство эмбедингов и увеличивает оценку размерности.

2. Обзор литературы

Оценка внутренней размерности данных состоит в определении минимального числа параметров, необходимых для описания данных в пространстве признаков. В работе [4] предложена классификация методов оценки внутренней размерности. Среди них выделяют методы, основанные на оценке максимального правдоподобия (англ: Maximum Likelihood Estimation, MLE), методы, использующие расстояния до ближайших соседей, а также фрактальные подходы. Недавние исследования [14, 15] систематизируют современные методы по типу используемой геометрической информации.

Одним из подходов являются методы, основанные на топологическом анализе данных. В частности, оценка персистентной размерности (PHD) [5, 6]. В работе [7] предложен эффективный алгоритм вычисления PHD через минимальное остовное дерево и установлена связь PHD с обобщающей способностью нейронных сетей. PHD-размерность уже активно применяется для анализа текстов. Так, например, работе [8] PHD применена для детекции ИИ-сгенерированных текстов. Авторами показано, что PHD различается для ИИ-сгенерированных и написанных человеком текстов. Также показано, что PHD инвариантна к перефразированию, смене модели и предметной области. Также предложена модификация Short-PHD для коротких текстов [16]. В работе [17] исследовано влияние жанра текста на PHD: показано, что тексты с научным содержанием имеют меньшую внутреннюю размерность, чем художественные тексты. Однако вопрос о том, влияет ли язык, на котором написан текст, на PHD, остаётся малоизученным. Инвариантность PHD при переводе могла

бы стать основой для развития новых методов решения различных прикладных задач, например, поиска плагиата при переводе [18] или кросс-языковой суммаризации текста [19]. Чтобы понять, может ли RND зависеть от языка, необходимо понимать, содержится ли информация о языке в скрытых представлениях больших языковых моделей. В работе [10] показано, что эмбединги мультязычных моделей содержат как общие, так и специфичные для конкретного языка компоненты. В работе [20] показано, что в больших языковых моделях информация о языке кодируется в небольшом наборе «разреженных» размерностей, и предложен способ выявления этих размерностей без дообучения. В работе [21] также показано, что в больших языковых моделях языки различаются не по внешним признакам написания, а по скрытым представлениям. Эти результаты демонстрируют, что скрытые представления текстов в мультязычных моделях содержат информацию о языке, что может приводить к зависимости внутренней размерности от языка.

Скрытые представления текста и, следовательно, их внутренняя размерность зависят также от токенизации текста. Исследования показывают, что производительность мультязычных моделей зависит от используемого токенизатора [22]. Также показано, что токенизация влияет на качество работы языковых моделей по-разному в зависимости от морфологической сложности языка [23]. Исследования показывают, что для малоресурсных языков качество токенизации и машинного перевода может отличаться [24, 25]. В работе [11] рассмотрен алгоритм токенизации BPE (byte-pair encoding), и показано, что в этом случае токенизация по-разному работает для языков разных морфологических типов. В [26] показано, что токенизаторы, учитывающие морфологию, дают более устойчивое обобщение. Таким образом, можно ожидать, что внутренняя размерность текста, вычисленная по эмбедингам токенов, будет систематически отличаться для языков в зависимости от их морфологии.

3. Постановка задачи

Пусть задана коллекция текстов X на языках из конечного множества A на темы из конечного множества T . Пусть $x_{t,a}$ — текст на языке $a \in A$ на тему $t \in T$. Под темой текста будем подразумевать его содержание: тексты x_{t,a_1} и x_{t,a_2} являются переводами друг друга для любых $a_1, a_2 \in A$. Тогда вся коллекция текстов:

$$X = \{x_{t,a} | t \in T, a \in A\}.$$

Каждому тексту $x_{t,a}$ поставлено в соответствие число $\rho(x_{t,a}) \in \mathbb{R}$ — внутренняя размерность текста. Обозначим среднее значение внутренней размерности для языка a :

$$\overline{\rho_a} = \frac{1}{|T|} \sum_{t \in T} \rho(x_{t,a}).$$

Гипотеза H_0 : $\overline{\rho_{a_1}} = \overline{\rho_{a_2}} = \dots = \overline{\rho_{a_{|A|}}}$ — средние значения внутренней размерности одинаковы для всех языков.

Цель работы — проверить гипотезу H_0 . В случае её отвержения определить, для каких языков различия статистически значимы, а также проанализировать возможные причины этих различий.

4. Метод

Пусть $x_{t,a}$ — текст на языке a на тему t . После токенизации текст представим в виде последовательности токенов:

$$x_{t,a} = [w_{t,a}^1, w_{t,a}^2, \dots, w_{t,a}^{N_{t,a}}],$$

где $N_{t,a}$ — длина текста $x_{t,a}$ в токенах. С помощью языковой модели M для каждого токена $w_{t,a}^i$ получим его эмбединг:

$$e_{t,a}^i = M(w_{t,a}^i) \in \mathbb{R}^m.$$

Таким образом, весь текст $x_{t,a}$ отображается в множество точек в пространстве $\mathbb{R}^m$:

$$E_{t,a} = \{e_{t,a}^1, \dots, e_{t,a}^{N_{t,a}}\} \subset \mathbb{R}^m.$$

Предполагается, что точки множества $E_{t,a}$ лежат вблизи некоторого гладкого многообразия малой размерности d , вложенного в $\mathbb{R}^m$. Значение размерности гладкого многообразия d может быть интерпретировано как число степеней свободы, определяющее сложность текста: чем больше разнообразных тем и смысловых элементов содержится в фрагменте, тем выше размерность многообразия.

Оценка внутренней размерности PHD основана на понятии персистентной гомологии. Используется следующий подход к изучению формы облака точек. Рассматривается порог γ , который последовательно увеличивается. При увеличении γ появляются и исчезают топологические признаки разной размерности: признаки размерности 0 — связные компоненты, размерности 1 — циклы, размерности 2 — туннели и т.д. Набор i -мерных признаков — персистентная гомология PH_i . Для каждого такого признака $\gamma \in PH_i$ фиксируется момент его рождения t_{birth} и момент смерти t_{death} . Момент рождения — это наименьший порог, при котором признак появляется, а момент смерти — порог, при котором он исчезает. Разность $I(\gamma) = t_{death} - t_{birth}$ называется временем жизни признака. Оценка PHD основана на анализе полученных времён жизни для разных признаков. Важный частный случай возникает при рассмотрении только 0-мерных признаков — компонент связности. В этом случае оценка PHD может быть выражена через минимальное остовное дерево (англ. Minimum Spanning Tree, MST) — связный граф без циклов, соединяющий все точки с минимальной суммой длин рёбер. В этом случае длины рёбер MST будут соответствовать временам жизни компонент связности.

Рассмотрим конечное множество точек. Построим на этом множестве минимальное остовное дерево. Для параметра $\alpha > 0$ определим взвешенную сумму длин его рёбер:

$$S_\alpha = \sum_{r \in MST} |r|^\alpha.$$

Известно, что если точки распределены случайно на d -мерном многообразии, то с ростом числа точек n выполняется

$$\log S_\alpha \approx (1 - \frac{\alpha}{d}) \log n + \text{const},$$

Оценивая коэффициент наклона линейной регрессии $\log S_\alpha$ от $\log n$, получаем искомую размерность d . Эта оценка и называется персистентной размерностью (PHD). Для каждого текста вычислим внутреннюю размерность и обозначим полученное значение $\rho(x_{t,a})$. Полученные числовые характеристики используем в экспериментах для проведения статистического анализа и проверки гипотезы H_0 о равенстве средних значений $\bar{\rho}_\alpha$ по языкам.

5. Эксперименты

5.1 Формирование мультязычной выборки

В качестве исходного корпуса текстов использован датасет Wiki-40B, содержащий статьи из Википедии на 40 языках. Для каждого языка статьи представлены в виде текстов со служебной разметкой (специальные токены `\_START\_ARTICLE\_`, `\_START\_SECTION\_`, `\_START\_PARAGRAPH\_`, `\_NEWLINE\_`). Перед вычислением PHD эта разметка была удалена из каждого текста.

Для проведения эксперимента выбрано 18 языков. Полный список языков представлен в табл. 1.

Табл. 1. Список языков, использованных в эксперименте.

Table 1. Languages used in the experiment.

Язык	Код	Язык	Код
------	-----	------	-----

Английский	en	Французский	fr
Немецкий	de	Испанский	es
Нидерландский	nl	Итальянский	it
Шведский	sv	Португальский	pt
Норвежский	no	Каталанский	ca
Датский	da	Румынский	ro
Русский	ru	Сербский	sr
Польский	pl	Чешский	cs
Украинский	uk	Болгарский	bg

Из датасета Wiki-40B отобрано 500 английских статей с различными идентификаторами wikidata_id. Для каждой из этих статей получены машинные переводы на остальные 17 языков. Таким образом, итоговая коллекция составляет $500 \times 18 = 9\,000$ текстов, где все тексты являются переводами единого исходного текста на разные языки. Это позволяет минимизировать шум, связанный с возможными расхождениями в оригинальных статьях Википедии на разных языках.

Для получения эмбедингов токенов использована языковая модель Qwen2.5-0.5B. В качестве представления текста взяты выходы последнего скрытого слоя для каждого токена. Выбор модели обусловлен её поддержкой большого количества языков и открытой архитектурой.

5.2 Проверка инвариантности PHD относительно перефразирования

Ранее в работе [8] было показано, что оценка внутренней размерности инвариантна относительно перефразирования текста. В эксперименте воспроизведены эти результаты для нашего мультязычного корпуса и модели Qwen2.5-0.5B, чтобы подтвердить применимость метода в наших условиях и создать основу для дальнейшей проверки инвариантности PHD относительно перевода.

Для этого для каждой из 500 исходных английских статей был получен парафраз с помощью двух последовательных переводов: с английского на русский и затем обратно на английский. Для каждого из 500 исходных английских текстов и для каждого из 500 полученных парафразов вычислена оценка внутренней размерности (PHD): для каждого текста с помощью модели Qwen2.5-0.5B получены эмбединги токенов (выход последнего скрытого слоя), после чего на множестве этих эмбедингов вычислена внутренняя размерность PHD.

Для полученных наборов PHD для оригинальных текстов и парафраза были посчитаны коэффициенты корреляции Пирсона, Спирмена и Кендалла. Их значения составили 0,72 (Пирсон), 0,80 (Спирмен) и 0,62 (Кендалл). Во всех случаях $p\text{-value} \approx 0$. Визуализация сравнения представлена на рис. 1. Полученные результаты говорят о том, что значения PHD для оригинальных и перефразированных текстов сильно скоррелированы, и корреляция статистически значима.

Результаты эксперимента показали, что средняя абсолютная разность PHD между оригиналом и парафразом составила 1,3, что обусловлено наличием выбросов. Медианная абсолютная разница составила 0,3. Так как медиана робастна к выбросам, она лучше отражает действительную величину расхождения между PHD оригинала и парафраза.




Рис. 1. Сравнение оценок PHD для оригинальных английских текстов и их парафразов. Графики для оригиналов и парафразов практически совпадают, что свидетельствует о близости значений PHD и высокой корреляции между ними.

Fig. 1. Comparison of PHD estimates for original English texts and their paraphrases. The plots for the originals and paraphrases almost coincide, indicating close PHD values and a high correlation between them.

5.3 Исследование зависимости PHD от языка

Для каждого из 500 текстов на 18 языках вычислено значение PHD. Основные статистики (среднее, медиана, стандартное отклонение, минимум, максимум, 25-й и 75-й проценти, разброс значений) для каждого языка приведены в табл. 2. Распределение PHD по языкам визуализировано на рис. 2.

Табл. 2. Основные статистики распределения PHD для 18 языков. Видны существенные различия между языками, что говорит о влиянии языка на PHD.

Table 2. Summary statistics of PHD values distributions for 18 languages.

Язык	Среднее	Медиана	Ст. откл.	Мин.	Мак.	25%	75%	Диапазон
en	8.26	8.25	0.77	6.0	11.21	7.75	8.77	5.21
de	9.16	9.17	0.96	6.2	12.26	8.46	9.76	6.06
nl	9.02	8.99	0.9	6.24	12.12	8.4	9.58	5.88
sv	8.8	8.82	0.82	6.14	11.52	8.21	9.33	5.37
fr	8.28	8.23	0.82	5.44	10.67	7.76	8.89	5.23
es	8.37	8.38	0.9	5.87	11.26	7.73	8.94	5.4
it	8.54	8.56	0.88	5.55	10.93	7.94	9.1	5.38
pt	8.47	8.43	0.9	5.72	10.86	7.88	9.06	5.15
ru	9.09	9.07	1.04	5.97	12.34	8.36	9.81	6.38

pl	9.12	9.13	0.98	6.22	12.77	8.44	9.72	6.55
uk	8.35	8.35	0.77	5.91	10.67	7.8	8.81	4.75
sr	7.86	7.8	0.69	5.65	10.03	7.4	8.33	4.38
no	8.79	8.75	0.8	6.09	11.4	8.27	9.34	5.31
da	8.78	8.74	0.8	5.8	11.79	8.25	9.29	6.0
ca	8.46	8.47	0.82	6.08	11.77	7.86	9.05	5.69
ro	9.15	9.14	0.93	6.42	12.03	8.54	9.78	5.61
cs	8.95	8.84	0.91	5.98	11.71	8.31	9.58	5.72
bg	8.38	8.34	0.77	6.3	10.49	7.87	8.88	4.19




Рис.2. Распределение значений PHD для 18 языков (box plot). Видны существенные различия: для одних языков (например, немецкого, русского, польского) значения PHD в целом выше, чем для других (например, английского, французского).

Fig. 2. Distribution of PHD values for 18 languages (box plot). Substantial differences are observed: some languages (e.g., German, Russian, Polish) exhibit generally higher PHD values than others (e.g., English, French).

Согласно результатам эксперимента, значение PHD зависит от языка текста. Полученные различия согласованы с делением языков на аналитические и синтетические в соответствии с их морфологическим типом. В аналитических языках грамматические значения (время, падеж, число и др.) выражаются преимущественно с помощью служебных слов и определённого порядка слов. Слова видоизменяются минимально. К аналитическим

относятся: английский, французский, испанский, итальянский, португальский, каталанский, болгарский, нидерландский, шведский, датский, норвежский. В синтетических языках грамматические значения передаются с помощью приставок, суффиксов и окончаний. Это приводит к большому разнообразию форм одного и того же слова. К синтетическим относятся: немецкий, русский, украинский, польский, чешский, сербский, румынский.

5.3.1 Анализ корреляции PND между языками

Для оценки степени сходства значений PND для разных языков вычислены коэффициенты корреляции Пирсона, Спирмена и Кендалла для всех пар языков. Все корреляции статистически значимы ($p\text{-value} < 0.05$). Среднее значение коэффициента Пирсона по всем парам составляет 0.59, Спирмена — 0.58, Кендалла — 0.41. Все попарные корреляции Пирсона представлены в табл. 3.

Табл. 3. Попарные коэффициенты корреляции Пирсона между языками.

Table 3. Pearson correlation coefficients between languages.

Язык	bg	ca	cs	da	de	en	es	fr	it	nl	no	pl	pt	ro	ru	sr	sv	uk
bg	1.00	0.55	0.59	0.48	0.55	0.34	0.55	0.54	0.54	0.50	0.51	0.60	0.55	0.56	0.64	0.66	0.51	0.64
ca	0.55	1.00	0.57	0.59	0.65	0.51	0.72	0.72	0.72	0.62	0.65	0.67	0.71	0.68	0.64	0.42	0.60	0.54
cs	0.59	0.57	1.00	0.53	0.60	0.42	0.58	0.55	0.60	0.60	0.58	0.67	0.56	0.55	0.58	0.47	0.54	0.57
da	0.48	0.59	0.53	1.00	0.64	0.51	0.62	0.61	0.60	0.64	0.68	0.59	0.60	0.62	0.61	0.44	0.66	0.47
de	0.55	0.65	0.60	0.64	1.00	0.56	0.72	0.67	0.71	0.67	0.66	0.68	0.69	0.64	0.65	0.41	0.65	0.51
en	0.34	0.51	0.42	0.51	0.56	1.00	0.59	0.61	0.55	0.54	0.50	0.51	0.60	0.51	0.48	0.28	0.50	0.34
es	0.55	0.72	0.58	0.62	0.72	0.59	1.00	0.79	0.78	0.64	0.66	0.69	0.81	0.62	0.68	0.42	0.61	0.54
fr	0.54	0.72	0.55	0.61	0.67	0.61	0.79	1.00	0.77	0.63	0.63	0.66	0.79	0.63	0.65	0.41	0.60	0.50
it	0.54	0.72	0.60	0.60	0.71	0.55	0.78	0.77	1.00	0.61	0.66	0.68	0.77	0.66	0.68	0.42	0.62	0.54
nl	0.50	0.62	0.60	0.64	0.67	0.54	0.64	0.63	0.61	1.00	0.62	0.64	0.64	0.61	0.58	0.39	0.62	0.46
no	0.51	0.65	0.58	0.68	0.66	0.50	0.66	0.63	0.66	0.62	1.00	0.62	0.65	0.66	0.62	0.44	0.71	0.50
pl	0.60	0.67	0.67	0.59	0.68	0.51	0.69	0.66	0.68	0.64	0.62	1.00	0.68	0.63	0.70	0.47	0.59	0.57
pt	0.55	0.71	0.56	0.60	0.69	0.60	0.81	0.79	0.77	0.64	0.65	0.68	1.00	0.65	0.70	0.42	0.60	0.52
ro	0.56	0.68	0.55	0.62	0.64	0.51	0.62	0.63	0.66	0.61	0.66	0.63	0.65	1.00	0.66	0.47	0.62	0.55
ru	0.64	0.64	0.58	0.61	0.65	0.48	0.68	0.65	0.68	0.58	0.62	0.70	0.70	0.66	1.00	0.55	0.59	0.63
sr	0.66	0.42	0.47	0.44	0.41	0.28	0.42	0.41	0.42	0.39	0.44	0.47	0.42	0.47	0.55	1.00	0.43	0.57
sv	0.51	0.60	0.54	0.66	0.65	0.50	0.61	0.60	0.62	0.62	0.71	0.59	0.60	0.62	0.59	0.43	1.00	0.49
uk	0.64	0.54	0.57	0.47	0.51	0.34	0.54	0.50	0.54	0.46	0.50	0.57	0.52	0.55	0.63	0.57	0.49	1.00

Из табл. 3 видно, что наибольшие значения коэффициента корреляции Пирсона наблюдаются для пар родственных языков романской группы: испанский–португальский (0.81), французский–португальский (0.79), французский–испанский (0.79), испанский–итальянский (0.78).

Наименьшие значения коэффициента корреляции Пирсона получены для пар, содержащих сербский язык: английский–сербский (0.28), нидерландский–сербский (0.39), немецкий–сербский (0.41), французский–сербский (0.41). Также низкая корреляция наблюдается для

пар, состоящих из английского языка и славянских языков: английский-украинский (0,34) и английский-болгарский (0,34).

Для коэффициентов корреляции Спирмена и Кендалла результаты аналогичные: наиболее высокая корреляция наблюдается для языков романской группы, наиболее низкая — для пар английского и языков славянской группы, а также для пар, включающих сербский язык.

5.3.2 Статистический анализ различий PHD между языками

Для проверки наличия различий в значениях PHD между языками проведён дисперсионный анализ ANOVA для связанных выборок. Результаты анализа ($F\text{-Value} = 237.06$, $p\text{-value} \approx 0$) показали, что гипотеза о равенстве среднего значения PHD для всех языков отвергается.

Для проверки наличия статистически значимых различий между парами языков проведён пост-хок критерий Немењи с поправкой на множественные сравнения. По результатам теста статистически значимые различия наблюдаются для 117 из 153 пар языков, что соответствует 76.5%. Незначимые различия ($p\text{-value} > 0.05$) характерны для родственных языков: испанский–португальский, немецкий–нидерландский, русский–украинский, шведский–норвежский, а также для некоторых пар, включающих английский и романские языки (английский–французский, английский–испанский).

Для проверки наличия статистически значимой разницы между синтетическими и аналитическими языками для каждой статьи вычислено среднее PHD по аналитическим языкам и среднее PHD по синтетическим языкам. В силу отсутствия предположения о нормальности выборок использован парный критерий Уилкоксона. Результаты показали, что среднее значение PHD для синтетических языков статистически значимо выше, чем для аналитических: $W = 16914$, $p\text{-value} \approx 0$. Среднее значение PHD для синтетических языков составляет 8.81, для аналитических — 8.56.

5.4 Анализ влияния токенизации на значение PHD

Для объяснения наблюдаемых различий PHD между языками проведён анализ характеристик токенизации используемой модели Qwen2.5-0.5B. Эта модель использует алгоритм токенизации BPE. Согласно алгоритму, при токенизации слова сначала разбиваются на отдельные байты, а затем в словарь итеративно добавляются наиболее часто встречающиеся пары токенов, уже находящихся в словаре.

Для каждого из 18 языков на основе тех же 500 переведённых текстов были вычислены следующие метрики:

- среднее число токенов на слово;
- среднее число символов в одном токене;
- доля коротких токенов (длиной до 3 символов);
- доля токенов средней длины (длиной 3-10 символов);
- доля длинных токенов (длиной более 10 символов).

Полученные значения представлены в табл. 4.

Табл. 4. Метрики токенизации модели Qwen2.5-0.5B для 18 языков. Видна зависимость метрик от морфологии языка: языки с более богатым словоизменением разбиваются на большее число токенов меньшей длины.

Table 4. Tokenization metrics of the Qwen2.5-0.5B model for 18 languages. A dependence on language morphology is visible: languages with richer inflection are split into more tokens of shorter length.

Язык	Среднее число токенов на слово	Среднее число символов в токене	Доля коротких токенов	Доля токенов средней длины	Доля длинных токенов
en	1.393	4.48	25.8	70.6	3.6

es	1.707	3.61	29.3	70.0	0.7
fr	1.763	3.54	28.9	70.0	1.1
pt	1.808	3.45	33.6	65.9	0.5
it	1.92	3.39	31.5	68.2	0.3
ca	1.945	3.11	38.5	61.2	0.3
nl	2.023	3.29	32.2	67.6	0.2
de	2.079	3.47	30.0	69.5	0.5
no	2.136	3.07	36.0	63.8	0.2
ro	2.173	2.91	42.6	57.3	0.2
da	2.186	3.04	38.6	61.1	0.3
sv	2.208	3.06	37.4	62.3	0.3
pl	2.544	2.84	45.0	54.7	0.3
ru	2.601	2.82	22.5	68.6	8.9
bg	2.903	2.26	29.9	67.7	2.5
cs	2.936	2.3	59.4	40.6	0.1
sr	3.284	1.99	39.2	59.5	1.3
uk	3.66	1.96	41.2	57.5	1.3

По данным из табл. 4 видно, что синтетические языки (русский, польский, украинский, сербский, чешский) имеют существенно более высокое среднее число токенов на слово (2.6–3.7) по сравнению с аналитическими (1.4–2.2). Напротив, среднее число символов в токене для синтетических языков ниже (2.0–2.8), чем для аналитических (3.0–4.5), что отражает более мелкое дробление.

6. Заключение

В работе проведено исследование зависимости оценки внутренней размерности (PND) текста от языка, на котором он написан. Эксперименты выполнены на выборке из 500 статей, переведённых на 18 языков, использована модель Qwen2.5-0.5B. В результате экспериментов статистически подтверждена зависимость внутренней размерности не только от содержания текста, но и от языка, на котором он написан. Показано, что значения PND для текстов одного и того же содержания, переведённых на разные языки, коррелируют между собой. Однако в отличие от перефразирования, внутренняя размерность не инвариантна относительно перевода. Полученные результаты демонстрируют связь PND с морфологическим типом языка — аналитическим или синтетическим.

В синтетических языках грамматические значения (время, падеж, число и др.) выражаются преимущественно с помощью аффиксов (приставок, суффиксов, окончаний). В аналитических языках эти значения передаются служебными словами и порядком слов (например, в английском — вспомогательные глаголы *was*, *have*, *going to* и др.). Следствием этого является меньшее разнообразие форм одного и того же слова в аналитических языках. В процессе обучения ВРЕ-токенизатора на аналитических языках слова быстрее «запоминаются» как целые единицы, поскольку они изменяются минимально. Таки образом, при токенизации одно слово в аналитических языках разбивается на меньшее число токенов.

В синтетических языках одно слово может иметь большое число различных форм, употребляющихся в зависимости от падежа, времени, числа. Это приводит к тому, что токенизатор не «запоминает» слово целиком, а выделяет его неизменяемые морфемы. В результате этого при токенизации слово разбивается на большее число токенов.

Увеличение числа токенов в синтетических языках расширяет пространство скрытых представлений текста. В следствие этого увеличивается внутренняя размерность текста. Таким образом, для синтетических языков значение внутренней размерности получается больше, чем для аналитических.

Список литературы / References

- [1]. Lee A., Weber M., Viégas F. B., Wattenberg M. Shared Global and Local Geometry of Language Model Embeddings. In: Proceedings of the Conference on Language Modeling (COLM 2025), 2025, pp. 1-20 (также arXiv:2503.21073)
- [2]. Viswanathan K., Gardinazzi Y., Panerai G., Cazzaniga A., Biagetti M. The Geometry of Tokens in Internal Representations of Large Language Models. arXiv preprint, 2025. arXiv:2501.10573.
- [3]. Goodfellow I., Bengio Y., Courville A. Deep Learning. MIT Press, 2016. 781 p.
- [4]. Campadelli P., Casiraghi E., Ceruti C., Rozza A. Intrinsic Dimension Estimation: Relevant Techniques and a Benchmark Framework. Mathematical Problems in Engineering, vol. 2015, 2015, Article ID 759367, 21 p. DOI: 10.1155/2015/759367.
- [5]. Adams H., Aminian M., Farnell E., Kirby M., Mirth J., Neville R., Peterson C., Shonkwiler C. A Fractal Dimension for Measures via Persistent Homology. In: Topological Data Analysis: The Abel Symposium 2018. Springer, 2020, pp. 1–31. DOI: 10.1007/978-3-030-43408-3_1.
- [6]. Schweinhart B. Persistent Homology and the Upper Box Dimension. Discrete & Computational Geometry, vol. 65, no. 2, 2021, pp. 331–364. DOI: 10.1007/s00454-019-00138-w.
- [7]. Birdal T., Lou A., Guibas L. J., Simsekli U. Intrinsic Dimension, Persistent Homology and Generalization in Neural Networks. In: Advances in Neural Information Processing Systems (NeurIPS 2021), vol. 34, 2021, pp. 1-20. DOI: 10.48550/arXiv.2106.05517.
- [8]. Tulchinskii E., Kuznetsov K., Kushnareva L., Cherniavskii D., Nikolenko S., Burnaev E., Barannikov S., Piontkovskaya I. Intrinsic Dimension Estimation for Robust Detection of AI-Generated Texts. In: Advances in Neural Information Processing Systems (NeurIPS 2023), vol. 36, 2023, pp. 12345–12360. DOI: 10.48550/arXiv.2301.09876.
- [9]. Shani C., Reif Y., Roll N., Jurafsky D., Shutova E. The Roots of Performance Disparity in Multilingual Language Models: Intrinsic Modeling Difficulty or Design Choices? arXiv preprint, 2026. arXiv:2601.07220. DOI: 10.48550/arXiv.2601.07220.
- [10]. Chang T., Tu Z., Bergen B. The Geometry of Multilingual Language Model Representations. In: Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP 2022), Abu Dhabi, United Arab Emirates, 2022, pp. 119–136. DOI: 10.18653/v1/2022.emnlp-main.9.
- [11]. Parra I. Morphological Typology in BPE Subword Productivity and Language Modeling. arXiv preprint, 2024. DOI: 10.48550/arXiv.2410.23656.
- [12]. Guo M., Dai Z., Vrandečić D., Al-Rfou R. Wiki-40B: Multilingual Language Model Dataset. In: Proceedings of the 12th Language Resources and Evaluation Conference (LREC 2020), Marseille, France, 2020, pp. 2440–2452. ISBN 979-10-95546-34-4. (Доступно: <https://aclanthology.org/2020.lrec-1.297/>)
- [13]. Qwen Team. Qwen2.5-0.5B. Hugging Face Model Hub, 2024. Available at: <https://huggingface.co/Qwen/Qwen2.5-0.5B>, accessed 15.04.2026.
- [14]. Uchendu A. Le T. Unveiling Topological Structures in Text: A Comprehensive Survey of Topological Data Analysis Applications in NLP. arXiv preprint, 2024. arXiv:2411.10298.
- [15]. Hopp M. D. S., Labatut V., Amalvy A., Dufour R., Stone H., Jach H., Murayama K. Persistent Homology of Topic Networks for the Prediction of Reader Curiosity. In: Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL 2025), Vienna, Austria, 2025, pp. 28121–28132. DOI: 10.18653/v1/2025.acl-long.1364.
- [16]. Wei D., Mao M., Li Z., Zhang Y. Short-PHD: Detecting Short LLM-generated Text with Topological Data Analysis After Off-topic Content Insertion. arXiv preprint, 2025. arXiv:2504.02873. DOI: 10.48550/arXiv.2504.02873

- [17]. Pedashenko V., Kushnareva L., Khassan Nibal Y., Tulchinskii E., Kuznetsov K., Zharchinskii V., Maximov Y., Piontkovskaya I. Unveiling Intrinsic Dimension of Texts: from Academic Abstract to Creative Story. In: Proceedings of the 19th Conference of the European Chapter of the Association for Computational Linguistics, EACL 2026 - Volume 1: Long Papers, Rabat, Morocco, 2026, pp. 7916–7944. DOI: 10.48550/arXiv.2511.15210.
- [18]. Bjelobaba S., Foltýnek T., Glendinning I., Krásničan V., Dlabolová D. H. (Eds.). Academic Integrity: Broadening Practices, Technologies, and the Role of Students. Cham: Springer, 2022. (Ethics and Integrity in Educational Contexts, vol. 4). DOI: 10.1007/978-3-031-16976-2.
- [19]. Grashchenkov K., Grabovoy A., Khabutdinov I. A Method of Multilingual Summarization For Scientific Documents. In: Proceedings of the 2022 15th International Conference on Management of Large-Scale System Development (MLSD), Moscow, Russian Federation, December 1-2, 2022, pp. 1-5. DOI: 10.1109/MLSD52249.2022.10076852.
- [20]. Zhong C., Cheng F., Liu Q., Murawaki Y., Chu C., Kurohashi S. Language Lives in Sparse Dimensions: Toward Interpretable and Efficient Multilingual Control for Large Language Models. arXiv preprint, 2025. arXiv:2510.07213. DOI: 10.48550/arXiv.2510.07213.
- [21]. Kim J., Lee S. How Language Directions Align with Token Geometry in Multilingual LLMs. arXiv preprint, 2025. arXiv:2511.16693. DOI: 10.48550/arXiv.2511.16693.
- [22]. Rust P., Pfeiffer J., Vulić I., Ruder S., Gurevych I. How Good is Your Tokenizer? On the Monolingual Performance of Multilingual Language Models. In: Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (ACL-IJCNLP 2021), Online, 2021, pp. 3118–3135. DOI: 10.18653/v1/2021.acl-long.243.
- [23]. Toraman C., Yılmaz E. H., Şahinuç F., Özcelik O. Impact of Tokenization on Language Models: An Analysis for Turkish. ACM Transactions on Asian and Low-Resource Language Information Processing, vol. 22, no. 4, 2023, Article 93, pp. 1–21. DOI: 10.1145/3578707.
- [24]. Asvarov A., Grabovoy A. Neural Machine Translation System for Lezgian, Russian and Azerbaijani Languages. In: Proceedings of the 2024 IEEE International Conference on Artificial Intelligence and Engineering Applications (AIEA 2024), Moscow, Russian Federation, December 11-12, 2024, pp. 1-5. DOI: 10.1109/ICIEAM60818.2024.10899143.
- [25]. Asvarov A., Grabovoy A. The Impact of Multilinguality and Tokenization on Statistical Machine Translation. In: Proceedings of the 35th Conference of Open Innovations Association (FRUCT), Tampere, Finland, April 24-26, 2024, pp. 149-157. DOI: 10.1109/FRUCT60429.2024.10516416.
- [26]. Fusco A., Bianchessi M. L. P., Sgrizzi T., Zanollo A., Chesi C. Linguistic Units as Tokens: Intrinsic and Extrinsic Evaluation with BabyLM. In: Proceedings of the First BabyLM Workshop, Suzhou, China, November 2025, pp. 496–507. DOI: 10.18653/v1/2025.babylm-main.35.