

Зависимость внутренней размерности текста от языка

Кучина Марина Александровна

Московский физико-технический институт

Курс: Автоматизация научных исследований
(практика, В. В. Стрижов)/Группа 331в

Эксперт: к.ф.-м.н., А. В. Грабовой

Консультант: студент магистратуры 5 курс И. Д. Папай

2026

Цель исследования

- ▶ **Мотивация:** Уже доказана инвариантность внутренней размерности при перефразировании. Наличие инвариантности при переводе позволило бы использовать внутреннюю размерность в прикладных кросс-языковых задачах: суммаризация, поиск плагиата.
- ▶ **Гипотеза:** Внутренняя размерность инвариантна относительно перевода.
- ▶ **Цель:** Проверить гипотезу на мультязычном корпусе. В случае отвержения проанализировать возможные причины различия внутренней размерности между языками.

- ▶ Tulchinskii et al.: *Intrinsic Dimension Estimation for Robust Detection of AI-Generated Texts*.
Оценка внутренней размерности PHD инвариантна к перефразированию.
- ▶ Birdal et al.: *Intrinsic Dimension, Persistent Homology and Generalization in Neural Networks*.
Алгоритм вычисления PHD через MST.
- ▶ Chang et al.: *The Geometry of Multilingual Language Model Representations*.
Влияние языка на эмбединги в мультязычных моделях.
- ▶ Parra: *Morphological Typology in BPE Subword Productivity and Language Modeling*.
Связь BPE-токенизации и морфологии языка.

Постановка задачи

Пусть задана коллекция текстов X на языках из конечного множества A на темы из конечного множества T :

$$X = \{x_{t,a} \mid t \in T, a \in A\},$$

где $x_{t,a}$ — текст на языке $a \in A$ на тему $t \in T$. Тексты на одну тему на разных языках считаются переводами друг друга.

Каждому тексту $x_{t,a}$ поставлено в соответствие число $\rho(x_{t,a}) \in \mathbb{R}$ — внутренняя размерность текста.

Среднее значение внутренней размерности для языка a :

$$\bar{\rho}_a = \frac{1}{|T|} \sum_{t \in T} \rho(x_{t,a})$$

Гипотеза H_0

$$\bar{\rho}_{a_1} = \bar{\rho}_{a_2} = \dots = \bar{\rho}_{a_{|A|}}$$

Внутренняя размерность текста и метод её оценки

Предполагается, что эмбединги токенов приближённо лежат на многообразии меньшей размерности d . Размерность d называется **внутренней размерностью текста** и характеризует его сложность.

В работе используется оценка на основе персистентной гомологии (англ. persistent homology dimension, **PHD**), которая вычисляется через построение минимального остовного дерева (англ. Minimum Spanning Tree, MST) на эмбедингах токенов.

Алгоритм вычисления PND

1. Токенизация текста $x_{t,a}$.
2. Получение эмбеддингов токенов $\{\mathbf{e}_{t,a}^i\}$ с помощью языковой модели.
3. Построение минимального остовного дерева (MST) на множестве точек $\{\mathbf{e}_{t,a}^i\}$.
4. Подсчёт взвешенной суммы рёбер: $S_\alpha = \sum_{r \in MST} |r|^\alpha$.
5. Из теории вероятностей при $n \rightarrow \infty$:

$$\log S_\alpha \approx \left(1 - \frac{\alpha}{d}\right) \log n + \text{const},$$

где d — внутренняя размерность.

6. Оценка размерности d получается из коэффициента наклона линейной регрессии.

- ▶ Датасет: Wiki-40B
- ▶ Корпус текстов: 500 оригинальных статей на английском, машинный перевод на 17 других языков.
- ▶ Языковая модель: Qwen2.5-0.5B (HuggingFace).

Вычислительный эксперимент: инвариантность при перепарафразировании




Рис. 1: Сравнение PHD оригинальных текстов и их парафразов.

Метод	Коэф. корреляции	p-value
Пирсон	0.7226	6.46e-81
Спирмен	0.7978	4.76e-111
Кендалл	0.6219	1.34e-95

Медианная абсолютная
разность PHD для
оригинального текста на
английском языке и
парафраз равна 0.3.
Значения сильно
скоррелированы.

Вычислительный эксперимент: распределение PHD по языкам





Рис. 2: Распределение значений PHD для 18 языков.

Присутствуют значительные различия между распределениями PHD для разных языков: для одних языков значения PHD в целом выше, чем для других.

Вычислительный эксперимент: корреляция PHD между языками



Значения PHD
сильно
скоррелированы.

Среднее значение
коэффициента
корреляции
Пирсона — 0.59.

Рис. 3: Корреляции PHD между языками.

Статистический анализ: различия PHD между языками

- ▶ ANOVA для связанных выборок: $F = 237.06$, $p\text{-value} \approx 0$ — гипотеза о равенстве всех средних значений PHD между языками отвергается.
- ▶ Пост-хок критерий Немецьки: 117 из 153 пар языков (76.5%) имеют значимые различия.
- ▶ Среднее значение PHD варьируется от 7.86 (сербский) до 9.16 (немецкий).

Влияние морфологического типа языка на PHD

- ▶ **Синтетические языки** (русский, немецкий, польский и др.) имеют PHD статистически значимо выше, чем **аналитические** (английский, французский, испанский, болгарский и др.).
- ▶ Критерий Уилкоксона: $p\text{-value} \approx 0$, есть статистически значимая разница между синтетическими и аналитическими языками.
- ▶ Среднее PHD: синтетические — 8.81, аналитические — 8.56.

Синтетические языки выражают грамматические значения с помощью аффиксов (приставок, суффиксов, окончаний); **аналитические** — с помощью служебных слов и порядка слов.

Почему синтетические языки дают более высокую PHD?

- ▶ Модель Qwen2.5-0.5B использует BPE-токенизацию.
- ▶ В синтетических языках слова имеют много форм, поэтому при BPE-токенизации разбиваются на большее число токенов (например, английский — 1.4 токена на слово, испанский — 1.7; русский — 2.6, польский — 2.5).
- ▶ Больше токенов $\Rightarrow$ шире пространство эмбедингов $\Rightarrow$ выше оценка внутренней размерности.

Основные результаты

- ▶ подтверждена инвариантность PHD относительно перефразирования;
- ▶ выявлена высокая корреляция PHD между разными языками;
- ▶ гипотеза об инвариантности PHD относительно перевода отвергнута;
- ▶ выявлена закономерность: для синтетических языков PHD статистически значимо выше, чем для аналитических.